

Algoritmi e complessità

Indice

1. Lezione 01 [26/09]	3
1.1. Notazione	3
1.1.1. Insiemi numerici	3
1.1.2. Monoide libero	3
1.1.3. Funzioni	3
1.2. Algoritmi 101	4
2. Lezione 02 [03/10]	7
2.1. Upper e lower bound	7
2.2. Classi di complessità [1]	7
2.3. Problemi di ottimizzazione	9
2.4. Classi di complessità [2]	11
3. Lezione 03	13
3.1. Max Matching	13
3.2. Load Balancing	15
4. Lezione 04 [10/10]	18
4.1. Ancora Load Balancing	18
4.2. Center Selection	19
5. Lezione 05 [11/10]	23
5.1. Ancora Center Selection	23
5.2. Set Cover	25
5.2.1. Funzione armonica	25
5.2.2. Definizione del problema	26
6. Lezione 06 [17/10]	28
6.1. Ancora Set Cover	28
6.2. Vertex Cover	30
7. Lezione 07 [18/10]	35
7.1. Ancora Vertex Cover	35
7.2. Problema dei cammini disgiunti (disjoint paths)	36

1. Lezione 01 [26/09]

1.1. Notazione

1.1.1. Insiemi numerici

Useremo i principali **insiemi numerici** come $\mathbb{N}, \mathbb{Z}, \mathbb{Q}, \mathbb{R}$ e, ogni tanto, le loro versioni con soli elementi positivi $\mathbb{N}^+, \mathbb{Z}^+, \mathbb{Q}^+, \mathbb{R}^+$.

1.1.2. Monoide libero

Un **magma** è una struttura algebrica (A, \cdot) formata da un insieme e un'operazione. Se essa è:

- dotata di \cdot **associativa** allora è detta **semigrupp**;
- dotata di un elemento $\bar{e} \in A$ tale che

$$\forall x \in A \quad x \cdot e = e \cdot x = x$$

allora è detta **monoide**; l'elemento \bar{e} è chiamato **elemento neutro** e in un monoide esso è unico; alcuni monoidi importanti sono $(\mathbb{N}, +)$ oppure $(\mathbb{N}, *)$

- dotata di \cdot **commutativa** allora si aggiunge **abeliano** alla sua definizione

Un **monoide libero** è un monoide i cui elementi sono generati da una base. Vediamo un importante monoide libero che useremo spesso durante il corso.

Partiamo da un **alfabeto** Σ , ovvero un insieme finito non vuoto di lettere/simboli. Definiamo Σ^* come l'insieme di tutte le sequenze di lettere dell'alfabeto Σ ; queste sequenze sono dette parole/stringhe e una generica parola è $w \in \Sigma^*$ nella forma $w = w_0 \dots w_{n-1} \mid n \geq 0 \wedge w_i \in \Sigma$. Usiamo $n \geq 0$ perché esiste anche la **parola vuota** ε . L'insieme Σ^* è numerabile.

Data una parola $w \in \Sigma^*$ indichiamo con $|w|$ il numero di simboli di w . La parola vuota è tale che $|\varepsilon| = 0$.

Un'operazione che possiamo definire sulle parole è la **concatenazione**: l'operazione è

$$\cdot : \Sigma^* \times \Sigma^* \longrightarrow \Sigma^*$$

ed è tale che, date

$$x = x_0 \dots x_{n-1} \quad y = y_0 \dots y_{m-1} \mid x, y \in \Sigma^*$$

posso calcolare $z = x \cdot y$ come

$$z = x_0 \dots x_{n-1} y_0 \dots y_{m-1}.$$

Dato il magma (Σ^*, \cdot) , esso è:

- semigrupp perché \cdot associativa;
- non abeliano perché \cdot non commutativa (lo sarebbe se $\Sigma = \{x\}$);
- dotato di neutro $e = \varepsilon$.

Ma allora (Σ^*, \cdot) è un monoide. Esso è anche un monoide libero su Σ .

1.1.3. Funzioni

Chiamiamo

$$B^A = \{f \mid f : A \longrightarrow B\}$$

l'insieme di tutte funzioni da A in B ; usiamo questa notazione perché la cardinalità di questo insieme, se A e B sono finiti, ha cardinalità $|B|^{|A|}$.

Spesso useremo un numero K come “insieme”: questo va inteso come l’insieme formato da K termini, ovvero l’insieme $\{0, 1, \dots, k-1\}$. Ad esempio, $0 = \emptyset$, $1 = \{0\}$, $2 = \{0, 1\}$, eccetera.

Date queste due definizioni, vediamo qualche insieme particolare.

Indichiamo con 2^A l’insieme

$$\{f \mid f : A \longrightarrow \{0, 1\}\},$$

ovvero l’insieme delle funzioni che classificano gli elementi di un A in un dato sottoinsieme di A , cioè ogni funzione determina un certo sottoinsieme. Possiamo quindi dire che

$$2^A \simeq \{X \mid X \text{ sottoinsieme di } A\}.$$

Questo insieme si chiama anche **insieme delle parti**, si indica con $\mathcal{P}(A)$ e ha cardinalità $2^{|A|}$ se A è finito.

Indichiamo con A^2 l’insieme

$$\{f \mid f : \{0, 1\} \longrightarrow A\}$$

l’insieme che rappresenta il **prodotto cartesiano**: infatti,

$$A^2 \simeq A \times A.$$

Indichiamo con 2^* l’insieme delle stringhe binarie, ma allora l’insieme 2^{2^*} è la famiglia di tutti i linguaggi binari, ad esempio \emptyset , 2^* , $\{\varepsilon, 0, 00, 000, \dots\}$, eccetera.

1.2. Algoritmi 101

In questo corso vedremo una serie di algoritmi che useremo per risolvere dei problemi, ma cos’è un problema?

Un problema Π è formato da:

- un insieme di input possibili $I_\Pi \subseteq 2^*$;
- un insieme di output possibili $O_\Pi \subseteq 2^*$;
- una funzione $\text{Sol}_\Pi : I_\Pi \longrightarrow 2^{O_\Pi}/\{\emptyset\}$; usiamo l’insieme delle parti come codominio perché potrei avere più risposte corrette per lo stesso problema.

Se in un problema mi viene chiesto di “decidere qualcosa”, siamo davanti ad un **problema di decisione**: questi problemi sono particolari perché hanno $O_\Pi = \{0, 1\}$ e hanno **una sola risposta possibile**, vero o falso, cioè non posso avere un sottoinsieme di risposte possibili.

Un algoritmo per Boldi è una **Macchina di Turing**. Sappiamo già come è fatta, ovvero:

- nastro bidirezionale infinito con input e blank;
- testina di lettura/scrittura two-way;
- controllo a stati finiti;
- programma/tabella che permette l’evoluzione della computazione.

Perché usiamo una MdT quando abbiamo a disposizione una macchina a registri (RAM, WHILE, lambda-calcolo)?

La **tesi di Church-Turing** afferma un risultato molto importante che però possiamo dare in più “salse”:

- tutte le macchine create e che saranno create sono equivalenti, ovvero quello che fai con una macchina lo fai anche con l’altra;
- nessuna definizione di algoritmo può essere diversa da una macchina di Turing;
- la famiglia dei problemi di decisione che si possono risolvere è uguale per tutte le macchine;

- i linguaggi di programmazione sono Turing-completi, ovvero se ipotizziamo una memoria infinita allora è come avere una MdT.

Anche un computer quantistico è una MdT, come calcolo almeno, perché in tempo si ha la quantum supremacy.

Un **algoritmo** A per Π è una MdT tale che

$$x \in I_{\Pi} \rightsquigarrow \boxed{A} \rightsquigarrow y \in O_{\Pi}$$

tale che $y \in \text{Sol}_{\Pi}(x)$, ovvero quello che mi restituisce l'algoritmo è sempre la risposta corretta.

Ma tutti i problemi sono risolvibili? No, grazie Mereghetti.

Questo lo vediamo con le cardinalità:

- i problemi di decisione sono i problemi dell'insieme 2^{2^*} , ovvero data una stringa binaria (il nostro input) devo dire se essa sta o meno nell'insieme; questo insieme è tale che

$$|2^{2^*}| \approx |2^{\mathbb{N}}| \approx |\mathbb{R}|;$$

- i programmi non sono così tanti: visto che i programmi sono stringhe, e visto che Σ^* è numerabile, le stringhe su un linguaggio sono tali che $2^* \sim \mathbb{N}$.

Si dimostra che $\mathbb{N} \not\sim \mathbb{R}$, quindi sicuramente esistono dei problemi che non sono risolvibili.

Una volta che abbiamo ristretto il nostro studio ai solo problemi risolvibili (noi considereremo solo quelli) possiamo chiederci quanto efficientemente lo riusciamo a fare: questa branca di studio è detta **teoria della complessità**.

In questo ambito vogliamo vedere quante risorse spendiamo durante l'esecuzione dell'algoritmo o del programma.

Abbiamo in realtà due diverse teorie della complessità: algoritmica e strutturale.

La **teoria della complessità algoritmica** ci chiede di:

- stabilire se un problema Π è risolubile;
- se sì, con che costo rispetto a qualche risorsa.

Le risorse che possiamo studiare sono:

- tempo come numero di passi o tempo cronometrato;
- spazio;
- numero di CPU nel punto di carico massimo;
- somma dei tempi delle CPU;
- energia dissipata.

Noi useremo quasi sempre il **tempo**. Definiamo

$$T_A : I_{\Pi} \longrightarrow \mathbb{N}$$

funzione che ci dice, per ogni input, quanto ci mette l'algoritmo A a terminare su quell'input.

Questo approccio però non è molto comodo. Andiamo a raccogliere per lunghezza e definiamo

$$t_A : \mathbb{N} \longrightarrow \mathbb{N}$$

tale che

$$t_A(n) = \max\{T_A(x) \mid x \in I_{\Pi} \wedge |x| = n\}$$

che va ad applicare quella che è la filosofia **worst case**. In poche parole, andiamo a raccogliere gli input con la stessa lunghezza e prendiamo, per ciascuna categoria, il numero di passi massimo che è stato rilevato. Anche questa soluzione però non è bellissima: è una soluzione del tipo “STA ANDANDO TUTTO MALEEEEE” (grande cit.).

Abbiamo altre soluzioni? Sì, ma non sono il massimo:

- la soluzione **best case** è troppo sbilanciata verso il “sta andando tutto bene”;
- la soluzione **average case** è complicata perché serve una distribuzione di probabilità.

A questo punto teniamo l’approccio worst case perché rispetto agli altri due non va a rendere complicati i conti. Inoltre, prendere il massimo ci dà la certezza di non fare peggio di quel valore.

Useremo inoltre la **complessità asintotica**, ovvero per n molto grandi vogliamo vedere il comportamento dei vari algoritmi, perché “con i dati piccoli sono bravi tutti”.

Il simbolo per eccellenza è l’ O -grande: se un algoritmo ha complessità $O(f(n))$ vuol dire che $f(n)$ domina il tempo t_A del nostro algoritmo.

2. Lezione 02 [03/10]

2.1. Upper e lower bound

Fissato Π un problema, qual è la complessità di Π ? Mi interessa la complessità del problema, non del singolo algoritmo che lo risolve: in poche parole, sto chiedendo quale sia la complessità del migliore algoritmo che lo risolve.

Questa è quella che chiamiamo **complessità strutturale**: non guardo i singoli algoritmi ma i problemi nel loro complesso.

Durante questo studio abbiamo due squadre di operai che fanno due lavori:

- **upper bound**: cerchiamo una soluzione per l'algoritmo, e cerchiamo poi di migliorarla continuamente abbassandone la complessità; in poche parole, questa squadra cerca di abbassare sempre di più la soglia indicata con $O(f(n))$ per avere una soluzione sempre migliore;
- **lower bound**: cerchiamo di dimostrare che il problema non si può risolvere in meno di $f(n)$ risorse; in matematica, indichiamo questo "non faccio meglio" con $\Omega(f(n))$ e, al contrario dell'altra squadra, questo valore cerchiamo di alzarlo il più possibile; non dobbiamo esibire un algoritmo, una prova.

Piccolo appunto: dobbiamo stare comunque attenti alle costanti dentro O e Ω , quindi prendiamo tutte le complessità un po' con le pinze.

Quando le due complessità coincidono abbiamo chiuso la questione:

- non faccio meglio di $f(n)$,
- non faccio peggio di $f(n)$,

ma allora ci metto esattamente $f(n)$, a meno di costanti, e questa situazione si indica con $\Theta(f(n))$.

È molto raro arrivare ad avere una complessità con Θ : l'ordinamento di array è $\Theta(n \log(n))$, ma è uno dei pochi casi, di solito si ha gap abbastanza grande.

Il problema sorge quando l'upper bound è esponenziale e il lower bound è polinomiale, ci troviamo in una zona grigia che potrebbe portarci ad algoritmi molto efficienti o ad algoritmi totalmente inefficienti.

I problemi interessanti sono spesso nella zona grigia, menomale molti sono solo nella "zona polinomiale", purtroppo molti sono solo nella "zona esponenziale".

2.2. Classi di complessità [1]

Viene più comodo creare delle **classi di problemi** e studiarli tutti assieme.

Le due classi più famose sono P e NP :

- P è la classe dei problemi di decisione risolvibili in tempo polinomiale; ci chiederemo sempre se un problema Π sta in P , questo perché ci permetterà di scrivere degli algoritmi efficienti per tale problema;
- NP è la classe dei problemi di decisione risolvibili in tempo polinomiale su macchine non deterministiche.

Cosa sono le macchine non deterministiche? Supponiamo di avere un linguaggio speciale, chiamato N -python, che ha l'istruzione esotica

$$x = ?$$

che, quando viene eseguita, sdoppia l'esecuzione del programma, assegnando $x = 0$ nella prima istanza e $x = 1$ nella seconda istanza. Queste due istanze vengono eseguite in parallelo. Questa istruzione può essere però eseguita un numero arbitrario di volte su un numero arbitrario di variabili: questo

genera un **albero di computazioni**, nel quale abbiamo delle foglie che contengono uno dei tanti assegnamenti di 0 e 1 delle variabili “sdoppiate”.

Tutte queste istanze y_i che abbiamo nelle foglie le controlliamo:

- rispondiamo *SI* se **esiste** un *SI* tra tutte le y_i ;
- rispondiamo *NO* se **tutte** le y_i sono *NO*.

Questa macchina è però impossibile da costruire: posso continuare a forkare il mio programma, ma prima o poi le CPU le finisco per la computazione parallela.

Molti problemi che non sappiamo se stanno in P sappiamo però che sono in NP . Il problema più famoso è **CNF-SAT**: l’input è un’espressione logica in forma normale congiunta del tipo

$$\varphi = (x_1 \vee x_2) \wedge (x_4 \vee \neg x_5) \wedge (x_3 \vee x_1)$$

formata da una serie clausole unite da *AND*. Ogni clausola è combinazione di *letterali* (normali o negati) legati da *OR*.

Data φ formula in CNF, ci chiediamo se sia soddisfacibile, ovvero se esiste un’assegnazione che rende φ vera. Un assegnamento è una lista di valori di verità che diamo alle variabili x_i per cercare di rendere vera φ .

Questo problema è facilmente “scrivibile” in una macchina non deterministica: per ogni variabile x_i $i = 1, \dots, n$ eseguo l’istruzione magica $x_i = ?$ che genera così tutti i possibili assegnamenti alle variabili, che sono 2^n , e poi controllo ogni assegnamento alla fine delle generazioni. Se almeno uno rende vera φ rispondo *SI*. Il tempo è polinomiale: ho rami esponenziali ma ogni ramo deve solo controllare n variabili.

Come siamo messi con CNF-SAT? Non sappiamo se sta in P , ma sicuramente sappiamo che sta in NP . Tantissimi problemi hanno questa caratteristica.

Ma esiste una relazione tra le classi P e NP ?

La relazione più ovvia è $P \subseteq NP$: se un problema lo so risolvere senza l’istruzione magica in tempo polinomiale allora creo un programma in N -python identico che però non usa l’istruzione magica che viene eseguito in tempo polinomiale.

Quello che non sappiamo è l’implicazione inversa, quindi se $NP \subseteq P$ e quindi se $P = NP$. Questo problema è stato definito da **Cook**, che affermava di “avere portata di mano il problema”, e invece.

Abbiamo quindi due situazioni possibili:

- se $P = NP$ è una situazione rassicurante perché so che tutto quello che ho davanti è polinomiale;
- se $P \neq NP$ è una situazione meno rassicurante perché so che esiste qualcosa di non risolvibile ma non so se il problema che ho sotto mano ha o meno questa proprietà.

Per studiare questa funzione possiamo utilizzare la **riduzione in tempo polinomiale**, una relazione tra problemi di decisione. Diciamo che Π_1 è riducibile in tempo polinomiale a Π_2 , e si indica con

$$\Pi_1 \leq_p \Pi_2,$$

se e solo se $\exists f : I_{\Pi_1} \longrightarrow I_{\Pi_2}$ tale che:

- f è calcolabile in tempo polinomiale;
- $\text{Sol}_{\Pi_1}(x) = \text{SI} \iff \text{Sol}_{\Pi_2}(f(x)) = \text{SI}$.

Grazie a questa funzione riesco a cambiare, in tempo polinomiale, da Π_1 a Π_2 e, se riesco a risolvere una delle due, allora riesco a risolvere anche l’altra. Il \leq indica che il primo problema “non è più difficile” del secondo.

Teorema 2.2.1: Se $\Pi_1 \leq_p \Pi_2$ e $\Pi_2 \in P$ allora $\Pi_1 \in P$.

Teorema 2.2.2 (Teorema di Cook): Il problema CNF-SAT è in NP e

$$\forall \Pi \in NP \quad \Pi \leq_p CNF-SAT.$$

Questo teorema è un risultato enorme: afferma che CNF-SAT è un problema al quale tutti gli altri si possono ridurre in tempo polinomiale. In realtà CNF-SAT non è l'unico problema: l'insieme di problemi che hanno questa proprietà è detto insieme dei problemi **NP -completi**, ed è definito come

$$NP-C = \left\{ \Pi \in NP \mid \forall \Pi' \in NP \quad \Pi' \leq_p \Pi \right\}.$$

Per dimostrare che un problema è NP -completo basta far vedere che CNF-SAT si riduce a quel problema, vista la proprietà transitiva della riduzione polinomiale. Se un problema è in $NP-C$ lo possiamo definire come “roba probabilmente difficile”.

Corollario 2.2.2.1: Se $\Pi \in NP-C$ e $\Pi \in P$ allora $P = NP$.

Questo corollario ci permette di ridurre la ricerca ai soli problemi in $NP-C$.

2.3. Problemi di ottimizzazione

Durante questo corso non vedremo quasi mai problemi di decisione, ma ci occuperemo quasi interamente di **problemi di ottimizzazione**. Questi problemi sono un caso particolare dei problemi.

Dato Π un problema di ottimizzazione, allora questo è definito da:

- **input:** $I_\Pi \subseteq 2^*$;
- **soluzioni ammissibili:** esiste una funzione

$$\text{Amm}_\Pi : I_\Pi \longrightarrow 2^{2^*} / \{\emptyset\}$$

che mappa ogni input in un insieme di soluzioni ammissibili:

- **obiettivo:** esiste una funzione

$$c_\Pi : 2^* \times 2^* \longrightarrow \mathbb{N}$$

tale che $\forall x \in I_\Pi$ e $\forall y \in \text{Amm}_\Pi(x)$ la funzione $c_\Pi(x, y)$ mi dà il costo di quella soluzione; questa funzione è detta **funzione obiettivo**;

- **tipo:** identificatore di c_Π , che può essere una funzione di massimizzazione o minimizzazione, ovvero $T_\Pi \in \{\min, \max\}$.

Vediamo MAX-CNF-SAT, una versione alternativa di CNF-SAT. Questo problema è definito da:

- **input:** formula logiche in forma normale congiunta;
- **soluzioni ammissibili:** data φ formula, in questo insieme A ho tutti i possibili assegnamenti a_i delle variabili di φ ;
- **obiettivo:** $c_\Pi(\varphi, a_i \in A)$ deve contare il numero di *clausole* rese vere dall'assegnamento a_i ;

- **tipo:** $T_{\Pi} = \max$.

Sicuramente questo problema è non polinomiale: se ce l'avessimo questo mi tirerebbe fuori l'assegnamento massimo, che poi in tempo polinomiale posso buttare dentro CNF-SAT per vedere se φ con tale assegnamento è soddisfacibile, ma questo non è possibile perché CNF-SAT non è risolvibile in tempo polinomiale (o almeno, abbiamo assunto tale nozione).

Ad ogni problema di ottimizzazione Π possiamo associare un problema di decisione $\tilde{\Pi}$ con:

- **input:** $I_{\tilde{\Pi}} = \{(x, k) \mid x \in I_{\Pi} \wedge k \in \mathbb{N}\}$;
- **domanda:** la risposta sull'input (x, k) è
 - ▶ SI se e solo se $\exists y \in \text{Amm}_{\Pi}(x)$ tale che:
 - $c_{\Pi}(x, y) \leq k$ se $T_{\Pi} = \min$;
 - $c_{\Pi}(x, y) \geq k$ se $T_{\Pi} = \max$;
 - ▶ NO altrimenti.

Il valore k fa da bound al valore minimo o massimo che vogliamo accettare.

Vediamo il problema MAX-SAT:

- **inputs:** $I = \{(\varphi, k) \mid \varphi \text{ formula CNF} \wedge k \in \mathbb{N}\}$;
- **domanda:** la risposta a (φ, k) è SI se e solo se esiste un assegnamento che rende vere almeno k clausole di φ .

La classe di complessità che contiene i problemi di ottimizzazione Π risolvibili in tempo polinomiale è la classe PO .

Teorema 2.3.1: Se $\Pi \in PO$ allora il suo problema di decisione associato $\tilde{\Pi} \in P$.

Corollario 2.3.1.1: Se $\tilde{\Pi} \in NP-C$ allora $\Pi \notin PO$.

Noi useremo spesso problemi che hanno problemi di decisione associati $NP-C$. Ci sono dei problemi in PO ? Certo: i problemi di programmazione lineare sono tutti problemi in PO , ma noi ne vedremo almeno un altro di questa classe.

Cosa si fa se, dato un problema di decisione, vediamo che il suo associato è NPC?

Una possibile soluzione sono le **euristiche**, però non sappiamo se funzionano bene o funzionano male, perché magari dipendono molto dall'input.

Una soluzione migliore sono le **funzioni approssimate**: sono funzioni polinomiali che mi danno soluzioni non ottime ma molto vicine all'ottimo rispetto ad un errore che scegliamo arbitrariamente.

Dato Π problema di ottimizzazione, chiamiamo $\text{opt}_{\Pi}(x)$ il valore ottimo della funzione obiettivo su input x . Dato un algoritmo approssimato per Π , ovvero un algoritmo tale che

$$x \in I_{\Pi} \rightsquigarrow A \rightsquigarrow y \in \text{Amm}_{\Pi}(x)$$

mi ritorna una soluzione ammissibile, non per forza ottima, definisco **rapporto di prestazioni** il valore

$$R_{\Pi}(x) = \max \left\{ \frac{c_{\Pi}(x, y)}{\text{opt}_{\Pi}(x)}, \frac{\text{opt}_{\Pi}(x)}{c_{\Pi}(x, y)} \right\}.$$

Si dice che A è una α -approssimazione per Π se e solo se

$$\forall x \in I_{\Pi} \mid R_{\Pi} \leq \alpha.$$

In poche parole, su ogni input possibile vado male al massimo quanto α .

È una definizione un po' esotica ma funziona: se la funzione obiettivo è di massimizzazione allora la prima frazione ha

$$\text{num} \leq \text{den},$$

mentre la seconda frazione mi dà sempre un valore ≥ 1 , che quindi sarà il valore scelto per R_{Π} . Nel caso di funzione obiettivo di minimizzazione la situazione è capovolta.


Se $R_{\Pi} = 1$ allora l'algoritmo su quell'input è ottimo e mi dà la soluzione migliore. Se, ad esempio, $R_{\Pi} = 2$, allora ho ottenuto

- un costo doppio dell'ottimo (*minimizzazione*);
- un costo dimezzato dell'ottimo (*massimizzazione*).

Vorremmo sempre avere un algoritmo 1-approssimante perché siamo all'ottimo, ma se non riusciamo ad avere ciò vorremmo almeno esserci molto vicino.

2.4. Classi di complessità [2]

Quali altre classi esistono in questo zoo della classi di ottimizzazione?



In ordine, PO è la più piccola, poi ci sono le classi γ -APX, con $\gamma \in \mathbb{R}^{\geq 1}$, che rappresentano tutte le classi che contengono i problemi con algoritmi γ -approssimati. La classe che li tiene tutti è

$$APX = \bigcup_{\alpha \geq 1} \alpha\text{-APX}.$$

Una classe ancora più grande è $\log(n)$ -APX: questa classe non usa una costante per definirsi, ma più l'input diventa grande più l'approssimazione diventa peggiore. La classe generale è la classe $f(n)$ -APX.

Il container più grande di tutti è NPO , che contiene anche gli NPO -completi, classe trasversale a tutti gli APX.

Rompiamo l'ordine e vediamo infine altre due classi:

- $PTAS$ (*Polynomial Time Approximation Scheme*): classe che contiene gli algoritmi approssimabili a piacere;
- $FPTAS$ (*Fully Polynomial Time Approximation Scheme*): classe che mantiene un tempo polinomiale al ridursi dell'errore, visto che più l'errore è vicino a 1 e più tempo ci metto.

3. Lezione 03

3.1. Max Matching

Il primo (e unico) problema di ottimizzazione in *PO* che vedremo sarà il problema di **Max Matching**.

Questo problema è definito da:

- **input:** grafo $G = (V, E)$ non orientato e bipartito, ma quest'ultima condizione può anche essere tolta. Un grafo bipartito è un grafo nel quale i vertici sono divisi in due blocchi e i lati vanno da un vertice del primo blocco ad un vertice del secondo blocco (e viceversa, ma tanto è non orientato). In poche parole, non ho lati che collegano vertici nello stesso blocco, quindi siamo

POCO LGBTQ+ FRIENDLY (godo)

- **soluzioni ammissibili:** una soluzione ammissibile è un **matching** M , una scelta di lati tale che i vertici del grafo risultano incisi al più da un lato. In poche parole, **viva i matrimoni non poligami**, dobbiamo far sposare persone che si piacciono e solo una volta, ma accettiamo anche i single (come me);
- **obiettivo:** numero di match $|M|$;
- **tipo:** massimizzare il numero di match, quindi max.

Una soluzione in tempo polinomiale sfrutta l'**algoritmo del cammino aumentante**.

Un cammino aumentante si applica ad un grafo con un matching M parziale. Per trovare i cammini aumentanti ci serviranno i **vertici esposti**, ovvero vertici sui quali non incidono i lati presi nel matching.

Un **cammino aumentante** (*augmenting path*) è un cammino che parte e arriva su un vertice esposto e alterna "lati liberi" e lati di M . Se so che esiste un cammino aumentante, scambio i lati presi e quelli non presi facendo un'operazione di **switch**: il matching cambia ma soprattutto aumenta di 1 il numero di lati presi.

Questa è un'informazione pazzza: se so che esiste un cammino aumentante il matching non è massimo e lo posso quindi migliorare.

Lemma 3.1.1: Se esiste un cammino aumentante per il matching M allora M non è massimo.

Lemma 3.1.2: Se il matching M non è massimo allora esiste un cammino aumentante per M .

Dimostrazione 3.1.1: Sia M' un matching tale che $|M'| > |M|$, che esiste per ipotesi. I matching sono un insieme di lati, quindi potremmo avere:

- lati solo in M (M/M');
- lati solo in M' (M'/M);
- lati sia in M sia in M' ($M \cap M'$).

Prendiamo i lati che sono in

$$M \Delta M' = (M/M') \cup (M'/M) = (M \cup M') / (M \cap M')$$

differenza simmetrica dei due match.

Osserviamo che nessun vertice può avere più di due lati incidenti in $M \Delta M'$. Possiamo dire di più: se un vertice ha esattamente due lati incidenti allora questi arrivano da due match diversi per definizione di match.

Se disegniamo il grafo con i soli vertici che sono incisi dai lati di $M \Delta M'$, abbiamo solo vertici di grado 1 e vertici di grado 2. Un grafo di questo tipo ha solo cammini e cicli, non esiste altro.

Se consideriamo i cicli, essi sono formati da vertici di grado 2, che hanno due lati incidenti ma arrivano da due matching diversi. Questo implica che ogni ciclo copre lo stesso numero di lati di M/M' e lati di M'/M e hanno lunghezza pari. Ma visto che $|M'| > |M|$ deve esistere qualcosa nel grafo che abbia più lati di M' al suo interno.

Se non è un ciclo, allora è un cammino: infatti, quello detto poco fa sui cicli implica che esiste un cammino nel grafo che è formato da più lati di M'/M (*esattamente uno in più*), ovvero un cammino che inizia a finisce con lati di M'/M . Questo cammino, dal punto di vista di M , è aumentante: alterna lati di M con lati che non sono in M (*per definizione di differenza*) e ai bordi ci sono due vertici che non sono incisi da lati di M . ■

Per trovare un cammino aumentante dobbiamo fare una **visita di grafo**. Una visita è un modo sistematico che si usa per scoprire un grafo. Abbiamo tre tipi di nodi:

- nodi sconosciuti (*bianchi*);
- nodi conosciuti ma non ancora visitati, che sono in una zona detta **frontiera** (*grigi*);
- nodi visitati (*neri*).

Vediamo come funziona l'algoritmo di visita, usando la funzione $c(x) \leftarrow t$ che assegna al vertice x il colore t .

Algoritmo di visita

```
1: for  $x$  in  $V$ :
2:    $c(x) \leftarrow W$ 
3:  $F \leftarrow \{x_{\text{seed}}\}$ 
4:  $c(x_{\text{seed}}) \leftarrow G$ 
5: while  $F \neq \emptyset$ :
6:    $x \leftarrow \text{pick}(F)$ 
7:   visit( $x$ )
8:    $c(x) \leftarrow B$ 
9:   for  $y$  in neighbor( $x$ ):
10:    if  $c(y) == W$ :
11:       $F \leftarrow F \cup \{y\}$ 
12:       $c(y) \leftarrow G$ 
```

Se il grafo è **connesso** lo riesco a visitare tutto e ogni vertice lo visito una volta sola. Se non è connesso visito solo la componente connessa del seme e, per continuare la visita, devo mettere un nuovo seme nella frontiera per andare avanti. Questo algoritmo è quindi ottimo per trovare le **componenti connesse** del grafo.

La funzione `pick` determina il comportamento di questa visita: se utilizziamo uno **stack** stiamo facendo una DFS (*visita in profondità*), se utilizziamo invece una **pila** stiamo facendo una BFS (*visita in ampiezza*). Infatti, in base a come si comporta la funzione `pick` abbiamo un ordine di scelta dei nodi diverso.

La BFS è interessante perché, a partire dal seme, nella frontiera metto i nodi vicini al seme, poi i vicini dei vicini del seme, poi eccetera. In poche parole, visito nell'ordine i nodi alla stessa distanza dal seme. Questo è uno dei modi standard per calcolare le distanze in un grafo non orientato e non pesato. Andremo quindi ad usare una BFS per trovare i cammini aumentanti.

Find Augmenting

```

1:  $X \leftarrow$  vertici esposti in  $M$ 
2: for  $x$  in  $X$ :
3:   BFS( $x$ ) con alternanza di lati in  $M$  e lati fuori da  $M$ 
4:   se durante la ricerca trovo un altro vertice di  $X$ 
5:     ritorno il cammino trovato

```

La BFS ha tempo proporzionale al numero di lati, quindi Find Augmenting impiega tempo $O(nm)$. Quanti aumenti posso fare? Al massimo $\frac{n}{2}$, quindi ho $O\left(\frac{n^2}{2}m\right)$, che è al massimo $O(n^4)$.

Teorema 3.1.1: Bipartite Max Matching è in PO .

Corollario 3.1.1.1: Il problema di decisione Perfect Matching è in P .

Se il grafo non fosse bipartito avremmo l'**algoritmo di fioritura**, che non sfrutta la BFS.

3.2. Load Balancing

Usciamo fuori dai problemi in PO e vediamo il problema del **Load Balancing**. Esso è definito da:

- **input:** abbiamo tre dati:
 - $m > 0$ numero di macchine;
 - $n > 0$ numero di task;
 - $(t_i)_{i \in n} > 0$ durate dei task;
- **soluzione ammissibile:** funzione

$$\alpha : n \rightarrow m$$

che assegna ogni task ad una macchina. Il carico di una macchina j è la quantità

$$L_j = \sum_{i \mid \alpha(i)=j} t_i.$$

Il carico generale è

$$L = \max_j L_j;$$

- **funzione obiettivo:** L ;
- **tipo:** max.

Teorema 3.2.1: Load Balancing è *NPO*-completo.

Che problemi stanno in *NPO*? È difficile dare una definizione di non determinismo nei problemi di ottimizzazione, però possiamo definire *NPO-C*: un problema di ottimizzazione Π è *NPO*-completo se e solo se:

- $\Pi \in NPO$;
- $\tilde{\Pi} \in NP-C$.

Se un problema in *NPO-C* fosse polinomiale allora il suo problema di decisione associato sarebbe polinomiale, e questo non può succedere.

Vediamo un **algoritmo greedy**, una tecnica di soluzione che cerca di ottimizzare “in modo miope”, ovvero costruisce passo dopo passo la soluzione prendendo ogni volta la direzione che sembra ottima in quel momento.

Greedy Load Balancing

```
1: for  $i$  in  $m$ :
2:    $A_i \leftarrow \emptyset$  (task assegnate alla macchina)
3:    $L_i \leftarrow 0$  (carico della macchina)
4: for  $j$  in  $n$ :
5:    $i \leftarrow \arg \min_{i \in m} L_i$  (indice macchina con meno carico)
6:    $A_i \leftarrow A_i \cup \{j\}$ 
7:    $L_i \leftarrow L_i + t_j$ 
8:  $\alpha$  assegna ogni elemento di  $A_i$  alla macchina  $i$ 
```

Il tempo d'esecuzione di questo algoritmo è $O(nm)$, ed è molto comodo perché è possibile utilizzarlo anche **online**, ovvero quando i task non sono tutti conosciuti ma possono arrivare anche durante l'esecuzione dell'algoritmo.

Teorema 3.2.2: Greedy Load Balancing è una 2-approssimazione per Load Balancing.

Dimostrazione 3.2.1: Chiamiamo L^* il valore della funzione obiettivo nella soluzione ottima.

Osserviamo che:

1. vale la relazione

$$L^* \geq \frac{1}{m} \sum_j t_j,$$

ovvero il carico migliore ci mette almeno un tempo uguale allo “spezzamento perfetto”, cioè quello che assegna ad ogni macchina lo stesso carico (*caso ideale, che segue la media*);

2. vale la relazione

$$L^* \geq \max_j t_j,$$

ovvero una macchina deve impiegare almeno il tempo più grande tra quelli disponibili.

Guardiamo la macchina che dà il massimo carico, ovvero sia \tilde{i} tale che $L_{\tilde{i}} = L$ e sia \tilde{j} l'ultimo compito che le è stato assegnato. Se assegno \tilde{j} vuol dire che poco prima questa macchina era la più scarica, quindi

$$L_{\tilde{i}} - t_{\tilde{j}} = \underbrace{L_{\tilde{i}}'}_{\text{carico in quel momento}} \leq L_i \quad \forall i \in m.$$

Sommiamo rispetto al numero di macchine, quindi

$$\sum_{i \in m} L_{\tilde{i}} - t_{\tilde{j}} = m(L_{\tilde{i}} - t_{\tilde{j}}) \leq \sum_{i \in m} L_i = \sum_{j \in n} t_j.$$

Dividiamo tutto per m e otteniamo

$$L_{\tilde{i}} - t_{\tilde{j}} \leq \frac{1}{m} \sum_j t_j \stackrel{(1)}{\leq} L^*.$$

Sappiamo che

$$L = L_{\tilde{i}} = \underbrace{L_{\tilde{i}} - t_{\tilde{j}}}_{\leq L^*} + \underbrace{t_{\tilde{j}}}_{\leq L^* \text{ per (2)}} \leq 2L^*$$

quindi

$$R_{\text{GLB}} = \frac{L}{L^*} \leq 2. \quad \blacksquare$$

4. Lezione 04 [10/10]

4.1. Ancora Load Balancing

L'algoritmo Greedy Load Balancing non è **tight**, ovvero posso costruire un input che si avvicini molto all'approssimazione alla quale appartiene il problema.

Teorema 4.1.1: $\forall \varepsilon > 0$ esiste un input per Load Balancing tale che Greedy Load Balancing produce un output

$$2 - \varepsilon \leq \frac{L}{L^*} \leq 2.$$

Dimostrazione 4.1.1: Scelgo un numero di macchine $m > \frac{1}{\varepsilon}$ e un numero di task $n = m(m - 1) + 1$. Come sono fatti questi task? Li dividiamo come

$$\underbrace{\overset{1}{\blacksquare} \dots \overset{1}{\blacksquare}}_{m(m-1)} + \overset{m}{\blacksquare}.$$

Ragionando con un approccio greedy, assegno tutti gli $m(m - 1)$ task da 1 alle m macchine, quindi ognuna ha $m - 1$ task, poi manca solo quella che dura m , che assegno a caso visto che hanno tutte lo stesso carico. Il carico della macchina scelta sarà $L = m - 1 + m = 2m - 1$.

Ragionando invece su come dovrebbe essere la configurazione ottima, questa dovrebbe assegnare la task grande m alla prima macchina e le altre $m(m - 1)$ alle restanti $m - 1$ macchine, quindi ognuna, compresa la prima, ha ora un carico di m , quindi $L^* = m$.

Confrontiamo i due valori:

$$\frac{L}{L^*} = \frac{2m - 1}{m} = 2 - \frac{1}{m} \geq 2 - \varepsilon. \quad \blacksquare$$

Vediamo ora un algoritmo migliore per il Load Balancing.

Sorted Greedy Load Balancing

input

$m > 0$ numero di macchine

$n > 0$ numero di task

$(t_i)_{i \in n}$ durata di ogni task

1: Ordina in maniera decrescente l'insieme $(t_i)_{i \in n}$

2: Usa l'algoritmo Greedy Load Balancing

Teorema 4.1.2: Sorted Greedy Load Balancing è una $\frac{3}{2}$ -approssimazione per Load Balancing.

Dimostrazione 4.1.2: Osserviamo che se $n \leq m$ la soluzione prodotta è ottima. Consideriamo quindi il caso $n > m$.

Osserviamo inoltre che $L^* \geq 2t_m$, ovvero che $\frac{1}{2}L^* \geq t_m$, con

$$\underbrace{t_0 \geq \dots \geq t_m}_{m+1 \text{ task}} \geq t_{m+1} \geq \dots \geq t_{n-1}.$$

Infatti, la macchina che riceve 2 task ha carico

$$\geq t_i + t_j \geq 2t_m.$$

Sia \tilde{i} la macchina tale che $L_{\tilde{i}} = L$ indice della macchina con carico massimo. Se \tilde{i} ha un compito solo, la soluzione è ottima.

Consideriamo allora \tilde{i} con più di un compito: sia \tilde{j} l'ultimo compito assegnato a quella macchina. So che $\tilde{j} \geq m$, perché le prime m task le do ad ogni macchina i distinta, allora

$$L = L_{\tilde{i}} = \underbrace{L_{\tilde{i}} - t_{\tilde{j}}}_{\leq L^*} - \underbrace{t_{\tilde{j}}}_{\leq t_m \leq \frac{1}{2}L^*} \leq \frac{3}{2}L^*.$$

Ma allora

$$\frac{L}{L^*} \leq \frac{3}{2}. \quad \blacksquare$$

Graham nel 1969 ha poi dimostrato che questo algoritmo è una $\frac{4}{3}$ -approssimazione.

Hochbaum e Shmoys hanno dimostrato, nel 1988, che:

- Load Balancing è un problema *PTAS*;
- Load Balancing non è un problema *FPTAS*.

4.2. Center Selection

Vediamo un esempio: abbiamo un insieme di magazzini di Amazon e vogliamo scegliere tra questi dei “*super magazzini*”, ovvero magazzini ai quali gli altri magazzini si riferiscono. L'insieme di super magazzino più magazzini che si riferiscono al super magazzino è detto **cella di Voronoi**.

Uno **spazio metrico** è una coppia (Ω, d) con Ω insieme e $d : \Omega \times \Omega \rightarrow \mathbb{R}^{\geq 0}$ **metrica** che rispetta le seguenti proprietà:

- **simmetria:** $d(x, y) = d(y, x)$;
- **identità degli indiscernibili:** $d(x, y) = 0$ se e solo se $x = y$;
- **disuguaglianza triangolare:** $d(x, y) \leq d(x, z) + d(z, y)$, ovvero aggiungere una tappa intermedia al mio percorso non mi può mai far guadagnare della distanza.

Il nostro mondo, ad esempio, non è uno spazio metrico perché non rispetta la simmetria.

Su $\Omega = \mathbb{R}^n$ si usa quasi sempre la **metrica euclidea**, ovvero

$$d(\bar{x}, \bar{y}) = \sqrt{\sum_i (x_i - y_i)^2}.$$

Un'altra metrica molto famosa è quella **Manhattan**, la “*metrica dei taxi*”, ovvero mi è permesso spostarmi come a Manhattan, cioè in orizzontale e verticale, a gradino. La metrica è tale che

$$d(\bar{x}, \bar{y}) = \sum_i |x_i - y_i|$$

e, oltre ad essere uno spazio metrico, è una **ultra metrica**, ovvero $d(x, y) \leq \max\{d(x, z), d(y, z)\}$.

Fissato (Ω, d) spazio metrico, definiamo:

- **input:** insieme $S \subseteq \Omega$ di n punti in uno spazio metrico e un budget $k > 0$ che indica quanti magazzini voglio costruire;
- **soluzione accettabile:** insieme $C \subseteq S$ di centri, con $|C| \leq k$. Definisco:
 - $\text{dist}(x, A) = \min_{y \in A} d(x, y)$ minima distanza tra x e gli elementi di A ;
 - $\forall s \in S \quad \delta_C(s) = \text{dist}(s, C)$ raggio di copertura del nodo s ;
 - $\rho_C = \max_{s \in S} \delta_C(s)$ il massimo raggio di copertura;
- **obiettivo:** ρ_C ;
- **tipo:** min.

Vogliamo minimizzare il massimo raggio di copertura. Questo problema è un problema *NPO-C*.

Costruiamo una prima soluzione facendo finta di sapere un dato che però dopo non sapremo.

Center Selection Plus v1

input:

$$\left[\begin{array}{l} S \subseteq \Omega \mid |S| = n > 0 \\ k > 0 \\ r \in \mathbb{R}^{>0} \end{array} \right.$$

```

1:  $C \leftarrow \emptyset$  insieme dei centri scelti
2: while  $S \neq \emptyset$ :
3:    $\bar{s} \leftarrow \text{take-any-from}(S)$ 
4:    $C \leftarrow C \cup \{\bar{s}\}$ 
5:   for  $s$  in  $S$  tali che  $d(s, \bar{s}) \leq 2r$ :
6:      $S \leftarrow S / \{s\}$ 
7: if  $|C| \leq k$ 
8:   output  $C$ 
9: else
10:  output "Impossibile"
```

Teorema 4.2.1: Se Center Selection Plus emette un output allora esso è una $\frac{2r}{\rho^*}$ -approssimazione.

Dimostrazione 4.2.1: Se arriviamo alla fine dell'algoritmo vuol dire che S è stato svuotato, perché ogni $s \in S$ è stato cancellato da un certo \bar{s} per la sua distanza. Sappiamo che

$$\rho_C \leq \delta_C(s) \leq d(s, \bar{s}) \leq 2r,$$

ma allora

$$\frac{\rho_C}{\rho^*} \leq \frac{2r}{\rho^*}.$$

■

Teorema 4.2.2: Se $r \geq \rho^*$ l'algoritmo emette un output.

Dimostrazione 4.2.2: Sia C^* una soluzione ottima, cioè una serie di centri che ha come raggio di copertura ρ^* . Sia $\bar{s} \in C$, chiamiamo $\bar{c}^* \in C^*$ il centro al quale si riferisce \bar{s} nella soluzione ottima.

Sia X l'insieme dei punti che nella soluzione ottima C^* si rivolgono a \bar{c}^* , allora $\forall s \in X$ posso dire che

$$d(s, \bar{s}) \leq d(s, \bar{c}^*) + d(\bar{c}^*, \bar{s})$$

ma le due distanze sono più piccole del raggio di copertura ottimo perché si riferiscono a lui, quindi

$$d(s, \bar{s}) \leq 2\rho^* \leq 2r$$

ma allora verrebbero tutti cancellati da X quando seleziono s , come abbiamo scritto nell'algoritmo sopra.

Dopo $\leq k$ passi ho cancellato tutto, quindi ho un output.

■

Questi teoremi ci dicono che l'output è approssimato in base a r , che poi mi dà anche una cosa in più per capire se ho soluzioni. Ma che valori possiamo scegliere per r ? Andiamo a vedere:

- se $r = \rho^*$ allora ho una 2-approssimazione;
- se $r > \rho^*$ allora l'approssimazione diventa peggiore, ma abbiamo comunque un output;
- se $r < \frac{1}{2}\rho^*$ sto approssimando con $\frac{2r}{\rho^*} < \frac{\rho^*}{\rho^*} = 1$ che però è impossibile;
- se $\frac{1}{2}\rho^* \leq r < \rho^*$ è random.

Vorremmo sempre avere ρ^* ma non ce l'abbiamo.

Vediamo una versione di Greedy Center Selection che sarà utile la prossima lezione per dimostrare alcune proprietà.

Center Selection Plus v2

input:

$$\left[\begin{array}{l} S \subseteq \Omega \mid |S| = n > 0 \\ k > 0 \\ r \in \mathbb{R}^{>0} \end{array} \right.$$

- 1: $C \leftarrow \{\bar{s}\}$ per un certo $\bar{s} \in S$
- 2: while true:
- 3: if $\exists \bar{s} \in S \mid d(\bar{s}, C) > 2r$:

Center Selection Plus v2

```
4:   |  $C \leftarrow C \cup \{\bar{s}\}$ 
5:   | else
6:   |   | break
7: if  $|C| \leq k$ 
8:   | output  $C$ 
9: else
10:  | output "Impossibile"
```

Vediamo finalmente l'algoritmo che andremo poi a studiare, ovvero quello senza le indicazioni sul valore di r che tanto vorremmo.

Greedy Center Selection

input:

```
|  $S \subseteq \Omega \mid |S| = n > 0$ 
|  $k > 0$ 
1: if  $|S| \leq k$ :
2:   | output  $S$ 
3:  $C \leftarrow \{\bar{s}\}$  per un certo  $\bar{s} \in S$ 
4: while  $|C| < k$ :
5:   | seleziona  $\bar{s} \in S$  che massimizzi  $d(\bar{s}, C)$ 
6:   |  $C \leftarrow C \cup \{\bar{s}\}$ 
7: output  $C$ 
```

Con questo algoritmo scelgo esattamente k centri, il primo scelto a caso, gli altri $k - 1$ il più lontano possibile da quelli che ho già scelto.

5. Lezione 05 [11/10]

5.1. Ancora Center Selection

Ricordiamo il nostro obiettivo: scegliere dei centri che minimizzino il raggio di copertura, ovvero il massimo tra tutte le distanze punto-centro più vicino.

Vediamo come l'algoritmo della scorsa lezione approssima il mio Center Selection.

Teorema 5.1.1: Greedy Center Selection è una 2-approssimazione per Center Selection.

Dimostrazione 5.1.1: Ci servirà Center Selection Plus v2 per dimostrare questo teorema.

Per assurdo supponiamo che l'algoritmo Greedy Center Selection emetta una soluzione con $\rho > 2\rho^*$. Questo vuol dire che esiste un certo elemento $\tilde{s} \in S$ tale che $d(\tilde{s}, C) > 2\rho^*$.

Sia \bar{s}_i l' i -esimo centro aggiunto a C e sia \bar{C}_i l'insieme dei centri in quel momento; possiamo dire che

$$\underbrace{d(\bar{s}_i, \bar{C}_i)}_{\text{prendo massima distanza}} \geq d(\tilde{s}, C_i) \geq d(\tilde{s}, C) > 2\rho^*.$$

Questa esecuzione è una delle esecuzioni possibili di Center Selection Plus v2 quando $r = \rho^*$. Noi sappiamo che questo algoritmo produce un output corretto, quindi termina entro k iterazioni quando non ci sono più elementi a distanza maggiore di $2\rho^*$, quindi tutti gli $s \in S$ sono tali che $d(s, C) \leq 2\rho^*$ ma questo non è vero, perché esiste \tilde{s} tale che $d(\tilde{s}, C) > 2\rho^*$.

Questo è un assurdo, quindi la soluzione è tale che $\rho \leq 2\rho^*$ e quindi

$$\frac{\rho}{\rho^*} \leq 2. \quad \blacksquare$$

Questo algoritmo è un esempio di **inapprossimabilità** o di **algoritmo tight**, ovvero non esistono algoritmi che approssimano Center Selection in un modo migliore di una 2-approssimazione.

Teorema 5.1.2: Se $P \neq NP$ non esiste un algoritmo polinomiale che α -approssimi Center Selection per qualche $\alpha < 2$.

Dimostrazione 5.1.2: Usiamo il problema NP -C Dominating Set (*addome degli insetti*):

- input: grafo $G = (V, E)$ e $k > 0$;
- output: ci chiediamo se $\exists D \subseteq V \mid |D| \leq k$ tale che

$$\forall x \in V / \{D\} \quad \exists d \in D \mid xy \in E.$$

Questo problema deve scegliere dove mettere delle guardie in un grafo, ovvero dei nodi che coprono i nodi a loro adiacenti, in modo che tutti i nodi siano coperti.

Dati G e k input di Dominating Set dobbiamo costruire una istanza di Center Selection.

Partiamo con il definire lo spazio metrico (Ω, d) con:

- insieme $\Omega = S = V$;
- funzione distanza

$$d(x, y) = \begin{cases} 0 & \text{se } x = y \\ 1 & \text{se } xy \in E. \\ 2 & \text{se } xy \notin E \end{cases}$$

Dimostriamo che è uno spazio metrico:

- simmetria: banale;
- identità degli indiscernibili: banale;
- disuguaglianza triangolare: notiamo che in questa disuguaglianza

$$d(x, y) \leq d(x, z) + d(z, y)$$

abbiamo il membro di sinistra che può assumere valori in $\{1, 2\}$, stessa cosa per i due addendi del membro di destra, ma allora il membro di destra ha come valori possibili $\{2, 3, 4\}$, quindi vale la disuguaglianza triangolare.

Come budget prendiamo esattamente k numero di guardie.

Ho creato il mio input per Center Selection. Chiediamoci quanto vale $\rho^*(S, k)$, ma questa assume solo valori in $\{1, 2\}$ per come ho definito la distanza.

Quando ho distanza 1? Devo scegliere C con $|C| \leq k$ tale che tale che

$$\forall s \in S \quad d(s, C) \leq 1,$$

ovvero tutti i punti sono a distanza 1 dai loro centri. Ma allora $\exists C^* \subseteq S$ tale che

$$\min_{c \in C^*} d(s, c) = 1.$$

Essendo a distanza possiamo dire che $\exists C^* \subseteq S$ tale che

$$\forall s \in S \quad \exists c \in C^* \mid sc \in E.$$

Questa è esattamente la definizione di Dominating Set, e il nostro Dominating Set è esattamente C^* .

Noi abbiamo un algoritmo α -approssimante per Center Selection con $\alpha < 2$, che fa

$$(S, k) \rightsquigarrow \text{ALGORITMO} \rightsquigarrow \rho^*(S, k) \leq \underbrace{\rho(S, k)}_{\text{risultato}} \leq \alpha \rho^*(S, k).$$

Sappiamo che la distanza migliore è 1 o 2, ma allora:

- se $\rho^* = 1$ ottengo $1 \leq \rho(S, k) \leq \alpha$;
- se $\rho^* = 2$ ottengo $2 \leq \rho(S, k) \leq 2\alpha$.

Nel primo caso dico devo rispondere SI al problema di Dominating Set, nel secondo caso devo rispondere NO.

Ma questi è un assurdo: avrei un algoritmo polinomiale per Dominating Set, quindi deve valere per forza $\alpha \geq 2$ ■

5.2. Set Cover

5.2.1. Funzione armonica

Il prof dell'aula accanto è un chad:


non è qui per trasmettere informazioni, ma per trasmettere emozioni

Diamo prima una definizione di **funzione armonica**: essa è la funzione

$$H : \mathbb{N}^{>0} \rightarrow \mathbb{R}$$

tale che

$$H(n) = \sum_{i=1}^n \frac{1}{i}.$$



Vediamo due proprietà importanti di questa funzione.

La prima proprietà ci dà un **upper bound** alla funzione armonica, ovvero

$$H(n) \leq 1 + \int_1^n \frac{1}{x} dx = 1 + [\ln(x)]_1^n = 1 + \ln(n) - \ln(1) = 1 + \ln(n).$$

Questa la possiamo capire dal grafico: tutta l'area tra i rettangoli e la funzione $\frac{1}{x}$ la andiamo a prendere nella maggiorazione.

La seconda proprietà afferma che

$$\int_t^{t+1} \frac{1}{x} dx \leq \int_t^{t+1} \frac{1}{t} dx = \frac{1}{t} \int_t^{t+1} 1 dx = \frac{1}{t} \cdot [x]_t^{t+1} = \frac{1}{t} (t+1 - t) = \frac{1}{t}.$$

Stiamo dando un altro upper bound: visto che $\frac{1}{x}$ è decrescente possiamo stimare la sua area tra t e $t+1$ usando un rettangolo con altezza uguale all'altezza della funzione calcolata in t .

Questa proprietà ci dà un **lower bound** alla funzione armonica, ovvero

$$H(n) = \frac{1}{1} + \dots + \frac{1}{n} \geq \int_1^2 \frac{1}{x} dx + \dots + \int_n^{n+1} \frac{1}{x} dx = \int_1^{n+1} \frac{1}{x} dx = \ln(n+1).$$

Grazie a queste proprietà abbiamo trovato dei **bound** per la funzione armonica:

$$\ln(n+1) \leq H(n) \leq 1 + \ln(n).$$

5.2.2. Definizione del problema

Il problema di (*Min*) **Set Cover** ci chiede di coprire tutte le zone di una città con i mezzi di trasporto spendendo il meno possibile scegliendo tra una serie di offerte che coprono un certo numero di aree.

Vediamo la definizione di questo problema:

- **input:**
 - m insiemi S_0, \dots, S_{m-1} non per forza disgiunti tali che $U = \bigcup_{i \in m} S_i$; questo insieme viene detto **insieme universo** (*tutte le zone della città*);
 - m costi w_0, \dots, w_{m-1} associati ad ogni insieme S_i (*costo delle offerte*);
- **soluzioni ammissibili:** $I \subseteq m$ tale che $\bigcup_{i \in I} S_i = U$ (*scelgo offerte che mi coprono tutta la città*);
- **obiettivo:** $\sum_{i \in I} w_i$;
- **tipo:** min.

Questo problema è *NPO-C*. La motivazione principale è la presenza di due tendenze contrastanti:

- scelgo insiemi grandi per coprire il più possibile subito, ma vado a spendere troppo
- scelgo insiemi piccoli che mi vanno a costare poco, ma potrei prenderne così tanti da superare la soluzione precedente.

Costruiremo la nostra soluzione aggiungendo mano a mano ad un insieme le “offerte” scelte. La scelta di un’offerta la andiamo a fare guardando il numero di elementi nuovi che andrebbe a coprire: per avere una buona metrica guarderemo il rapporto tra quanto paghiamo e quanti elementi nuovi inseriamo, e lo andremo a minimizzare.

Greedy Set Cover

$R \leftarrow U$

$I \leftarrow \emptyset$

while $R \neq \emptyset$:

| scegli S_i che minimizzi $\frac{w_i}{|S_i \cap R|}$
 $I \leftarrow I \cup \{i\}$
 $R \leftarrow R / S_i$

output I

Il valore

$$\frac{w_i}{|S_i \cap R|}$$

è un **costo** che associamo ad ogni insieme: infatti, questo ci dà una indicazione di quanto paghiamo nello scegliere quell’insieme considerando sia il suo costo sia quanti nuovi elementi va a coprire. Indichiamo con $c(s)$ questa quantità $\forall s \in S_i \cap R$.

Lemma 5.2.2.1: Alla fine di Greedy Set Cover abbiamo

$$w = \sum_{s \in U} c(s).$$

Dimostrazione 5.2.2.1: Il costo totale delle offerte scelte è $w = \sum_{i \in I} w_i$, ma w_i è la somma di tutti i costi $c(s)$ associati ad ogni elemento di $s \in S_i \cap R$, quindi

$$w = \sum_{i \in I} \sum_{s \in S_i \cap R} c(s) = \sum_{s \in U} c(s).$$

■

Lemma 5.2.2.2: Per ogni k vale

$$\sum_{s \in S_k} c(s) \leq H(|S_k|)w_k.$$

Dimostrazione 5.2.2.2: Assumo $S_k = \{s_1, \dots, s_d\}$ enumerato in ordine di copertura.

Consideriamo l'iterazione che copre s_j usando un certo S_h , cosa possiamo dire di R ?

Sicuramente $\{s_j, s_{j+1}, \dots, s_d\} \subseteq R$ ma allora $|S_k \cap R| \geq d - j + 1$ e quindi

$$c(s_j) = \frac{w_h}{|S_k \cap R|} \leq \frac{w_k}{|S_k \cap R|} \leq \frac{w_k}{d - j + 1}.$$

Andiamo a valutare

$$\begin{aligned} \sum_{s \in S_k} c(s) &\leq \sum_{j=1}^d c(s_j) \leq \sum_{j=1}^d \frac{w_k}{d - j + 1} = \frac{w_k}{d} + \frac{w_k}{d-1} + \dots + \frac{w_k}{1} = \\ &= w_k \left(\frac{1}{1} + \dots + \frac{1}{d} \right) = w_k H(|S_k|). \end{aligned}$$

Non ho capito la prima minorazione.

■

6. Lezione 06 [17/10]

6.1. Ancora Set Cover

Teorema 6.1.1: Sia $M = \max_i |S_i|$, allora Greedy Set Cover è una $H(M)$ -approssimazione per Set Cover.

Dimostrazione 6.1.1: Sia I^* una soluzione ottima, ovvero un insieme di indici tali che

$$w^* = \sum_{i \in I^*} w_i.$$

Per il lemma 2 della scorsa lezione vale

$$w_i \geq \frac{\sum_{s \in S_i} c(s)}{H(|S_i|)} \geq \frac{\sum_{s \in S_i} c(s)}{H(M)}$$

perché $H(M) \geq H(|S_i|)$ vista la monotonia di H .

Possiamo scrivere anche che

$$\underbrace{\sum_{i \in I^*} \sum_{s \in S_i} c(s)}_{\text{più di una volta}} \geq \sum_{s \in U} c(s) = w.$$

Uniamo i due risultati e otteniamo

$$w^* = \sum_{i \in I^*} w_i \geq \sum_{i \in I^*} \frac{\sum_{s \in S_i} c(s)}{H(|S_i|)} \geq \frac{w}{H(M)}.$$

Ma allora

$$\frac{w}{w^*} \leq H(M). \quad \blacksquare$$

L'approssimazione che ho non è esatta, ma dipende dall'input.

Notiamo che $M \leq |U| = n$, ma $H(M) \leq H(n)$ per monotonia di H e quindi


$$H(M) \leq H(n) = O(\log(n)).$$

Corollario 6.1.1.1: Greedy Set Cover è una $O(\log(n))$ -approssimazione per Set Cover.

Questo qui è un **algoritmo tight**: infatti, riusciremo a creare un input ad hoc che si avvicina al tasso di approssimazione a meno di un errore molto piccolo.

Esempio 6.1.1: Il nostro universo è formato da:

- 2 insiemi A, B di costo $1 + \varepsilon$ con $\frac{n}{2}$ punti;
- 1 insieme *giallo* di costo 1 con $\frac{n}{2}$ punti, $\frac{n}{4}$ punti da A e $\frac{n}{4}$ punti da B ;
- 1 insieme *arancio* di costo 1 con $\frac{n}{4}$ punti, $\frac{n}{8}$ punti da A e $\frac{n}{8}$ punti da B ;
- 1 insieme *rosso* di costo 1 con $\frac{n}{8}$ punti, $\frac{n}{16}$ punti da A e $\frac{n}{16}$ punti da B ;
- eccetera.



Simuliamo l'algoritmo Greedy Set Cover su questo particolare input.

Prima iterazione:

- gli insiemi A, B hanno costo $\frac{2+2\varepsilon}{n}$;
- gli insiemi che pescano da A, B hanno costo $\frac{2}{n}, \frac{4}{n}, \frac{8}{n}$, eccetera.

L'algoritmo seleziona quindi l'insieme giallo con costo $\frac{2}{n}$. Rimangono da coprire $\frac{n}{2}$ elementi.

Seconda iterazione:

- gli insiemi A, B hanno costo $\frac{4+4\varepsilon}{n}$;
- gli insiemi che pescano da A, B hanno costo $\frac{4}{n}, \frac{8}{n}$, eccetera.

L'algoritmo seleziona quindi l'insieme arancio con costo $\frac{4}{n}$. Rimangono da coprire $\frac{n}{4}$ elementi.

E così via fino a quando non copro totalmente $A \cup B$ selezionando solo gli insiemi "trasversali". Ogni insieme costa 1 e gli insiemi sono $\log(n)$, quindi

$$w = \log(n).$$

Il costo ottimo si ottiene scegliendo gli insiemi A e B , quindi

$$w^* = 2 + 2\varepsilon.$$

L'approssimazione ottenuta è

$$\frac{w}{w^*} = \frac{\log(n)}{2 + 2\varepsilon} = \Omega(\log(n)).$$

Teorema 6.1.2: Se $P \neq NP$ non esiste un algoritmo che approssimi Set Cover meglio di $(1 - o(1)) \log(n)$.

Visti questi risultati, Set Cover finisce in $\log(n)$ -APX.

6.2. Vertex Cover


Il problema di **Vertex Cover** assomiglia spaventosamente a Dominating Set.

Vediamo da cosa è definito:

- **input:**
 - grafo non orientato $G = (V, E)$;
 - pesi $w_i \in \mathbb{R}^{>0} \quad \forall i \in V$;
- **soluzione ammissibile:** insieme di vertici $X \subseteq V$ tale che $\forall e \in E$ allora $e \cap X \neq \emptyset$, ovvero ogni lato deve avere almeno un vertice a lui incidente nell'insieme X ;
- **funzione obiettivo:** $\sum_{i \in X} w_i$;
- **tipo:** min.

Sembra il problema di Dominating Set ma ci sono differenze:

- in Dominating Set andiamo a scegliere una serie di vertici X , dette guardie, e tutti i vertici non scelti hanno un arco che va in almeno una guardia
- in Vertex Cover andiamo a scegliere una serie di vertici X e tutti i lati hanno almeno un vertice nell'insieme scelto.



Questa differenza

mi manda in sbattimento (cit. Boldi)

Se abbiamo un Vertex Cover allora abbiamo anche un Dominating Set.

Questo problema è ovviamente *NPO-C*. Noi vedremo un algoritmo basato sul pricing.

I **problemi basati sul pricing** sono problemi economici dove ho:

- agenti che pagano una certa quota per avere un certo servizio;
- agenti che decidono se entrare o meno nel gioco accettando o meno le offerte degli altri agenti.

I primi agenti sono i *lati*, che pagano una certa quota p_e per farsi coprire da un certo vertice, mentre i secondi sono i vertici, che vedono se entrare o meno nel gioco in base a quanto vengono pagati.

I vertici sono una gang, una mafia, vogliono massimizzare quello che portano a casa

Associamo ad ogni lato un prezzo che pagherebbero ai vertici incidenti per farsi coprire da loro.

Il **pricing** è un insieme di prezzi

$$(p_e)_{e \in E}.$$

Un pricing è **equo** se e solo se

$$\forall i \in V \quad \sum_{e \in E \wedge i \in e} p_e \leq w_i.$$

In poche parole, i lati che incidono sul vertice i devono offrire al massimo quello che chiede il vertice. È una mafia, perché dovrei dare di più? Noi useremo solo pricing equi. Il pricing equo più ovvio è quello che vale 0 su tutti i lati.

Lemma 6.2.1: Se $(p_e)_{e \in E}$ è un pricing equo allora

$$\sum_{e \in E} p_e \leq w^*.$$

Dimostrazione 6.2.1: Sappiamo che $X^* \subseteq V$ è una soluzione ottima e

$$w^* = \sum_{i \in X^*} w_i.$$

Per definizione di equità vale

$$\sum_{e \in E \wedge i \in e} p_e \leq w_i.$$

Sommiamo su tutti gli $i \in X^*$ quindi

$$\sum_{i \in X^*} \sum_{e \in E \wedge i \in e} p_e \leq \sum_{e \in E} p_e \leq \sum_{i \in X^*} w_i = w^*.$$

La prima disuguaglianza è vera perché selezionando tutti i vertici nella soluzione ottima X^* e poi tutti i lati che incidono su questi vertici potrei sommare più volte lo stesso lato. ■

Data un pricing, esso è **stretto** sul vertice i se e solo se

$$\sum_{e \in E \wedge i \in e} p_e < w_i.$$

È una proprietà che vale su un vertice, non su tutto il grafo. Questa proprietà afferma che il vertice i non è contento di quello che riceve, non riceve quello che vuole.

Pricing Vertex Cover

input

└ grafo $G = (V, E)$ non orientato
└ costi $w_i \in \mathbb{R}^{>0} \quad \forall i \in V$

1: $p_e \leftarrow 0 \quad \forall e \in E$

2: while $\exists e = (i, j)$ tale che $(p_e)_{e \in E}$ è stretto su i e su j :


3: └ sia \bar{e} il lato che minimizza $\Delta = \min \left(\left(w_i - \sum_{e \in E \wedge i \in e} p_e \right), \left(w_j - \sum_{e \in E \wedge j \in e} p_e \right) \right)$

4: └ $p_{\bar{e}} \leftarrow p_{\bar{e}} + \Delta$, ovvero alzo l'offerta del minimo indispensabile


5: output $\{i \in V \mid p_e \text{ non è stretto su } i\}$ insieme dei vertici contenuti

Esempio 6.2.1: Nelle seguenti figure abbiamo il peso di un vertice w_i indicato in violetto e quanto il vertice $i \in V$ viene pagato dai lati p_i indicato in rosso.


All'inizio dell'algoritmo siamo nella seguente configurazione, con il pricing banale.




Alla prima iterazione del while tutti i lati hanno entrambi i vertici con pricing stretto e tutti i lati verrebbero aggiornati con il valore 3. Scegliamo di modificare il lato AB .



Alla seconda iterazione del while i lati BC e CD hanno entrambi i vertici con pricing stretto, il lato BC verrebbe aggiornato con il valore 1. Scegliamo di modificare il lato BC .



Alla terza iterazione del while il lato CD ha entrambi i vertici con pricing stretto e verrebbe aggiornato con il valore 2. Scegliamo di modificare il lato CD .



Non eseguiamo più nessuna iterazione del while perché ogni lato ha almeno un vertice con pricing non stretto.

Selezioniamo quindi i vertici A, B e C che sono gli unici che hanno il pricing non stretto.

Perché siamo sicuri che questo algoritmo sia uno di approssimazione? Perché i lati non parlano tra di loro, non si mettono d'accordo su cosa fare.

7. Lezione 07 [18/10]

7.1. Ancora Vertex Cover

Chiudiamo la porta, c'è il prof che regala emozioni (cit. Boldi)

L'algoritmo che abbiamo visto non vuole avere lati con entrambi i vertici incidenti stretti: infatti, se così fosse quel lato non verrebbe coperto perché i vertici non sono invogliati ad entrare nell'affare.

Lemma 7.1.1: Alla fine di Pricing Vertex Cover abbiamo

$$w \leq 2 \sum_{e \in E} p_e.$$

Dimostrazione 7.1.1: Noi paghiamo

$$w = \sum_{i \in \text{out}_V} w_i$$

ma in output ho tutti i vertici non stretti sul pricing, quindi

$$w = \sum_{\substack{i \in V \mid p_e \text{ non} \\ \text{è stretto su } i}} w_i$$

ma il costo w_i è la somma di tutte le offerte dei lati incidenti, quindi

$$w = \sum_{i \in \text{out}_V} \sum_{e \in E \wedge i \in e} p_e.$$

Stiamo sommando per ogni vertice nell'output i lati a che incidono su di esso, ma questi compaiono al massimo due volte, ovvero se entrambi i vertici di un lato stanno nell'output, quindi

$$w \leq 2 \sum_{e \in E} p_e. \quad \blacksquare$$

Teorema 7.1.1: Pricing Vertex Cover è una 2-approssimazione per Vertex Cover.

Dimostrazione 7.1.2: Vediamo

$$\frac{w}{w^*} \leq \frac{2 \sum_{e \in E} p_e}{w^*} \leq \frac{2 \sum_{e \in E} p_e}{\sum_{e \in E} p_e} = 2. \quad \blacksquare$$

Non sappiamo molto di più: non sappiamo se possiamo andare meglio di 2, ma sappiamo che esiste un PTAS, ovvero non si conosce una γ -approssimazione con $\gamma < 2$. Siamo quindi in un caso di inapprossimabilità, ci sarà un minimo tasso ma non sappiamo quanto è.

7.2. Problema dei cammini disgiunti (disjoint paths)

Idea del problema: abbiamo grafo orientato con k sorgenti s_0, \dots, s_{k-1} e altrettante destinazioni t_0, \dots, t_{k-1} . Cerchiamo di creare il maggior numero di cammini $s_i \rightarrow t_i$ passando per i lati al massimo una volta. In realtà noi useremo un parametro di congestione c che ci permette di passare al massimo c volte per un lato.

Diamo una definizione a questo problema:

- **input:**
 - grafo $G = (N, A)$ orientato;
 - lista $s_0, \dots, s_{k-1} \in N$ di sorgenti;
 - lista $t_0, \dots, t_{k-1} \in N$ di destinazioni;
 - parametro di congestione $c \in \mathbb{N}^+$;
- **soluzione ammissibile:** insieme $I \subseteq k$ tale che i cammini $\pi_i : s_i \rightarrow t_i \quad \forall i \in I$ non usano archi di G più di c volte; in altre parole, ogni arco è usato al massimo da c cammini;
- **obiettivo:** $|I|$;
- **tipo:** max.

Usiamo anche una funzione di lunghezza

$$l : A \rightarrow \mathbb{R}^{>0}$$

che verrà modificata nel tempo e ci permetterà di implementare il prossimo algoritmo. Con questa funzione definiamo la **lunghezza di un cammino** come la quantità

$$l(\pi = \langle x_1, \dots, x_i \rangle) = l(x_1, x_2) + \dots + l(x_{i-1}, x_i).$$

Greedy Paths

input:

grafo $G = (N, A)$ orientato
 lista $s_0, \dots, s_{k-1} \in N$ di sorgenti
 lista $t_0, \dots, t_{k-1} \in N$ di destinazioni
 parametro di congestione $c \in \mathbb{N}^+$
 moltiplicatore $\beta > 1$

- 1: $I \leftarrow \emptyset$ (coppie già collegate)
- 2: $P \leftarrow \emptyset$ (cammini già fatti)
- 3: for $a \in A$:
- 4: $l(a) \leftarrow 1$
- 5: forever and ever:
- 6: trova il cammino più corto $\pi_i : s_i \rightarrow t_i$ con $i \notin I$ (coppia ancora non collegata)
- 7: if $\nexists \pi_i$:
- 8: break
- 9: $I \leftarrow I \cup \{i\}$
- 10: $P \leftarrow P \cup \{\pi_i\}$
- 11: $\forall a \in \pi_i$:
- 12: $l(a) \leftarrow \beta \cdot l(a)$

Greedy Paths

13: $\quad \quad$ if $l(a) = \beta^c$:
14: $\quad \quad$ \quad rimuovi a dal grafo
15: output I e P

Definizione 7.2.1 (Cammino corto): In un certo istante di esecuzione, un cammino π è **corto** se e solo se

$$l(\pi) < \beta^c.$$

I cammini si possono solo allungare, quindi il passaggio di “stato” è da *corto* a *lungo*.

Definizione 7.2.2 (Cammino utile): In un certo istante di esecuzione, un cammino π è **utile** se collega un coppia nuova $i \notin I$.

L’algoritmo considera solo cammini utili e, inoltre, ogni volta il più corto. All’inizio consideriamo cammini **corti e utili**, poi cammini **lungi e utili**, poi ci fermiamo.

Noi studieremo l’algoritmo quando finiamo i cammini corti. Sia \bar{l} la funzione lunghezza in quel momento e siano \bar{I} e \bar{P} le coppie già collegate con il loro percorso associato sempre in quel momento. Nella fase di output abbiamo l_o , I_o e P_o .

Lemma 7.2.1: Sia $i \in I^*/I_o$, allora

$$\bar{l}(\pi_i^*) \geq \beta^c.$$

Dimostrazione 7.2.1: Per assurdo sia

$$\bar{l}(\pi_i^*) < \beta^c.$$

Questo non è possibile: nel grafo avremmo un cammino corto che potremmo selezionare, ma noi abbiamo appena esaurito i cammini corti. ■

Lemma 7.2.2: Sia $m = |A|$, allora

$$\sum_{a \in A} \bar{l}(a) \leq \beta^{c+1} |\bar{I}| + m.$$

Dimostrazione 7.2.2: Dimostriamolo per induzione.

All'inizio dell'algoritmo abbiamo

$$\sum_{a \in A} l(a) = \sum_{a \in A} 1 = m \leq \beta^{c+1} |\bar{I}| + m.$$

Supponiamo ora che la lunghezza l_1 passi alla lunghezza l_2 scegliendo la coppia i -esima con il cammino π_i . Supponiamo inoltre di non essere ancora arrivati a \bar{l} .

Possiamo dire che

$$l_2(a) = \begin{cases} l_1(a) & \text{se } a \notin \pi_i \\ \beta l_1(a) & \text{se } a \in \pi_i \end{cases}.$$

Valutiamo la differenza

$$\begin{aligned} \sum_{a \in A} l_2(a) - \sum_{a \in A} l_1(a) &= \sum_{a \notin \pi_i} (l_2(a) - l_1(a)) + \sum_{a \in \pi_i} (l_2(a) - l_1(a)) = \\ &= \sum_{a \in \pi_i} (l_2(a) - l_1(a)) = \sum_{a \in \pi_i} (\beta l_1(a) - l_1(a)) = \\ &= (\beta - 1) \sum_{a \in \pi_i} l_1(a) = (\beta - 1) l_1(\pi_i) < (\beta - 1) \beta^c \\ &\leq \beta^{c+1} \end{aligned}$$

Ad ogni passo aggiungiamo un cammino, quindi la funzione lunghezza aumenta ogni volta di β^{c+1} . Noi facciamo $|\bar{I}|$ aggiunte prima di arrivare in \bar{I} , quindi aggiungiamo $\beta^{c+1} |\bar{I}|$, al quale aggiungiamo il valore iniziale m della lunghezza “spostandolo a destra”. ■

Facciamo un paio di osservazioni importanti per calcolare il γ dell'approssimazione.

Osserviamo che

$$\sum_{i \in I^*/I_o} \bar{l}(\pi_i^*) \geq \beta^c |I^*/I_o|$$

per il primo lemma di questa lezione.

Osserviamo anche che nella soluzione ottima nessun arco è usato più di c volte. Quindi possiamo maggiorare il costo con il costo di tutti gli archi moltiplicati per c , ovvero

$$\sum_{i \in I^*/I_o} \bar{l}(\pi_i^*) \leq c \sum_{a \in A} \bar{l}(a) \leq c(\beta^{c+1} |\bar{I}| + m).$$

L'ultima minorazione è per il lemma 2 di questa lezione.

Grazie a queste due osservazioni possiamo trovare il γ che approssima questo algoritmo.

Teorema 7.2.1: Greedy Path fornisce una $\left(2cm^{\frac{1}{c+1}} + 1\right)$ -approssimazione per Disjoint Paths.

Dimostrazione 7.2.3: Osserviamo anche che

$$\begin{aligned}
\beta^c |I^*| &\leq \beta^c |I^*/I_o| + \beta^c |I^* \cap I_o| \\
&\stackrel{o1}{\leq} \sum_{i \in I^*/I_o} \bar{l}(\pi_i^*) + \beta^c |I_o| \\
&\stackrel{o2}{\leq} c(\beta^{c+1} |\bar{I}| + m) + \beta^c |I_o| \\
&\leq c(\beta^{c+1} |I_o| + m) + \beta^c |I_o|.
\end{aligned}$$

Dividiamo tutto per β^c e otteniamo

$$|I^*| \leq c\beta |I_o| + \frac{cm}{\beta^c} + |I_o| \leq c\beta |I_o| + |I_o| \frac{cm}{\beta^c} + |I_o| = |I_o| \left(c\beta + \frac{cm}{\beta^c} + 1 \right).$$

Ma allora

$$\frac{|I^*|}{|I_o|} \leq c(\beta + m\beta^{-c}) + 1.$$

Vorremmo scegliere un β che minimizzi questa funzione: la soluzione gentilmente calcolata è

$$\beta = m^{\frac{1}{c+1}}.$$

Con questo valore otteniamo

$$\frac{|I^*|}{|I_o|} \leq c \left(m^{\frac{1}{c+1}} + m^{1-\frac{c}{c+1}} \right) = c \left(m^{\frac{1}{c+1}} + m^{\frac{1}{c+1}} \right) + 1 = 2cm^{\frac{1}{c+1}} + 1. \quad \blacksquare$$

Questa funzione è abbastanza sus: ha un fattore lineare moltiplicativo in c che peggiora l'approssimazione, ma al tempo stesso si alza anche l'indice della radice. Infatti:

- se $c = 1$ approssimo con $2\sqrt{m} + 1$;
- se $c = 2$ approssimo con $4\sqrt[3]{m} + 1$;
- se $c = 3$ approssimo con $6\sqrt[4]{m} + 1$;
- eccetera.